




Rysunek 1.6. Wyznaczanie osobnych grup za pomocą klasteryzacji


Redukowanie wymiarowości w celu kompresji danych

Kolejną dziedziną uczenia nienadzorowanego jest **redukcja wymiarowości** (ang. *dimensionality reduction*). Często pracujemy z danymi wielowymiarowymi — każda obserwacja daje nam dużą liczbę wartości pomiarowych — co stanowi wyzwanie w przypadku ograniczonej pojemności nośników danych oraz skuteczności obliczeniowej algorytmów uczenia maszynowego. Nienadzorowana redukcja wymiarowości jest stosowana powszechnie we wstępnym przetwarzaniu cech w celu wykluczenia szumu z danych — który może zmniejszać skuteczność predykcji niektórych algorytmów — a do tego kompresuje dane do podprzestrzeni o mniejszej liczbie wymiarów przy zachowaniu większości istotnej informacji.


Czasami redukowanie wymiarowości przydaje się również do wizualizacji danych — np. zbiór cech wielowymiarowych można rzutować na jedno-, dwu- lub trójwymiarowe przestrzenie cech w celu wyświetlenia go w formie dwu- lub trójwymiarowego wykresu punktowego albo histogramu. Rysunek 1.7 zawiera przykład zastosowania nieliniowej redukcji wymiarowości do skompresowania wykresu trójwymiarowego do nowej dwuwymiarowej podprzestrzeni cech.

Wprowadzenie do podstawowej terminologii i notacji

Po omówieniu trzech ogólnych kategorii uczenia maszynowego — nadzorowanego, nienadzorowanego oraz przez wzmacnianie — przyszedł czas na zapoznanie się z podstawową terminologią, która będzie wykorzystywana w kolejnych rozdziałach. Na rysunku 1.8 widzimy tabelę stanowiącą fragment zestawu danych *Iris*, będącego klasycznym przykładem w dziedzinie



Rysunek 1.7. Przykład redukowania wymiarowości



Rysunek 1.8. Fragment zestawu danych Iris

uczenia maszynowego. Na zbiór tych danych składają się wyniki pomiarów 150 kwiatów kosańca z trzech różnych gatunków: *Setosa* (kosaciec szczecinkowy), *Versicolor* (kosaciec różnobarwny) oraz *Virginica* (kosaciec wirginijski). Każdy kwiat reprezentuje tu oddzielny wiersz w zbiorze danych, natomiast wyniki pomiarów (w centymetrach) są przechowywane w kolumnach, zwanych także zbiorami cech.

Aby zachować prostotę i czytelność notacji oraz implementacji, wprowadzimy pewne podstawy **algebry liniowej**. W następnych rozdziałach będę opisywać dane w notacji **macierzowej** oraz **wektorowej**. Wykorzystam popularną konwencję, zgodnie z którą każda próbka jest reprezentowana jako osobny wiersz w macierzy cech X , gdzie poszczególne cechy są przechowywane w oddzielnych kolumnach.

Zestaw danych Iris, składający się ze 150 próbek i z 4 cech, możemy zapisać jako macierz o rozmiarze 150×4 lub $\mathbf{X} \in \mathbb{R}^{150 \times 4}$:

$$\begin{bmatrix} x_1^{(1)} & x_2^{(1)} & x_3^{(1)} & x_4^{(1)} \\ x_1^{(2)} & x_2^{(2)} & x_3^{(2)} & x_4^{(2)} \\ \vdots & \vdots & \vdots & \vdots \\ x_1^{(150)} & x_2^{(150)} & x_3^{(150)} & x_4^{(150)} \end{bmatrix}$$

W dalszej części książki będziemy wykorzystywać indeks górny (i) do określenia i -tej próbki uczącej, a indeks dolny (j) będzie odnosił się do j -tego wymiaru zbioru uczącego.

Pogrubionymi małymi literami będziemy oznaczać wektory: ($\mathbf{x} \in \mathbb{R}^{n \times 1}$), z kolei pogrubionymi dużymi literami będziemy określać macierze: ($\mathbf{X} \in \mathbb{R}^{n \times m}$). Pojedyncze elementy wektora lub macierzy definiujemy literami oznaczonymi kursywą (odpowiednio: $x^{(n)}$ lub $x_{(m)}^{(n)}$).

Na przykład element x_1^{150} oznacza pierwszy wymiar (czyli długość działki) próbki numer 150. W ten sposób każdy wiersz w tej macierzy cech reprezentuje jedno wystąpienie kwiatu, które można zapisać w postaci czteroelementowego wektora $\mathbf{x}^{(i)} \in \mathbb{R}^{1 \times 4}$, $\mathbf{x}^{(i)} = [x_1^{(i)} \quad x_2^{(i)} \quad x_3^{(i)} \quad x_4^{(i)}]$

Każdy wymiar cechy jest 150-elementowym wektorem kolumnowym $\mathbf{x}_j \in \mathbb{R}^{150 \times 1}$, np.:

$$\mathbf{x}_j = \begin{bmatrix} x_j^{(1)} \\ x_j^{(2)} \\ \vdots \\ x_j^{(150)} \end{bmatrix}$$

W podobny sposób przechowujemy zmienne docelowe (tutaj: etykiety klas), jako 150-elementowy wektor

$$\text{kolumnowy } \mathbf{y} = \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(150)} \end{bmatrix} \quad (y \in \{\text{Setosa, Versicolor, Virginica}\}).$$

Strategia tworzenia systemów uczenia maszynowego

W poprzednich podrozdziałach omówiliśmy podstawowe pojęcia uczenia maszynowego oraz poznaliśmy trzy jego rodzaje. Przyjrzymy się teraz innym istotnym elementom systemu uczenia maszynowego towarzyszącym algorytmom uczenia. Na rysunku 1.9 zaprezentowałem schemat typowego przebiegu procesów podczas stosowania uczenia maszynowego w **modelowaniu predykcyjnym**. Zagadnienie to rozwinie w dalszej części rozdziału.